SMOTE25

Data section ใน *manuscript* ชื่อ *"How the SMOTE Literature Uses Data"* มีบทนำ, *8* หัวข้อย่อย, *8* ตาราง และ *1* รูป ฉบับพรีวิวยาวประมาณ *12* หน้า

บทนำ

- ตั้งคำถามที่ผู้อ่านต้องการคำตอบ:
    - ชื่อ *dataset* เดียวกันเทียบกันได้ไหม
    - หลักฐานของวงการกว้างแค่ไหน
    - ข้อมูลยากแค่ไหน
    - ชนะ *SMOTE* บนข้อมูลแบบไหน
    - ตรวจย้อนได้ไหม
- ขอบเขต: *76 paper (ใช้ 73), dataset 1,654* รายการ, ผลเทียบกับ *SMOTE 835* และ *2,497* แถว
- ข้อสังเกตหลัก: หลักฐานตีความได้แค่เท่าที่คำอธิบายข้อมูลให้ และสรุปผลหลักของทั้งส่วนไว้ในย่อหน้าเดียว

1. Extraction Procedure

- เก็บอะไร, ป้ายชนิดข้อมูล *5* แบบ, กฎที่ใช้เมื่อ *paper* ไม่บอก
- กฎเลือก *metric* และ *classifier*, การลอกทุก *metric* และการตรวจกับ *PDF*

2. The Benchmark Landscape

- *771* ชื่อ ⟶ *680 dataset* ⟶ *459 family* และการกระจุกของการใช้งาน
- *split* จากแหล่งเดียวกันต่างกันแค่ไหน และผลบน *split* ไม่อิสระต่อกัน
- ตาราง: *benchmark* ผู้สมัคร *18* ชุด (กลุ่ม *F/D/V*)

- ข้อแนะนำให้นับ *family* และข้อจำกัดของหลักฐาน

3. How Datasets Are Chosen and Modified

- ตาราง: เหตุผลการเลือกข้อมูล และชนิดข้อมูลของทั้ง *1,654* รายการ
- การดัดแปลงแบ่งเป็นแบบไหนบ้าง และส่วนที่ไม่ได้ประกาศ (*93* จาก *331* รายการทำซ้ำไม่ได้)

4. The Same Name Is Not the Same Data

- *90* จาก *192 dataset* มีหลายขนาด และกรณี *MWMOTE*
- ตาราง: นิยาม *IR* ที่พบในเปเปอร์ และตัวอย่าง *IR* ที่ผิดแล้วถูกส่งต่อกันไป

5. How Difficult Are the Datasets That Can Be Checked?

- นิยามว่า "ตรวจได้" คืออะไร, วิธีวัด (*Napierala + HVDM)* และเกณฑ์ที่มีอ้างอิง
- ตาราง: โปรไฟล์ความยาก *(113 task binary, 171 task OvR)*
- รูป: *(a) noise index* แยกตามโปรไฟล์ (*b)* จำนวน *feature* ทั้ง *corpus*
- *IR* บอกความยากได้น้อย, ข้อมูลเป็นตารางมิติต่ำ, เปเปอร์ส่วนใหญ่ใช้หลายโปรไฟล์ปนกัน
- ตาราง: ชุด *dataset* อ้างอิง *27 task* สำหรับให้ผู้อ่านนำไปใช้
- ข้อจำกัดของการวัด

6. Where Reported Wins over SMOTE Come From

- นิยาม *win/loss* และภาพรวม *1,511* คู่ ชนะ *79.5%*
- ตาราง: ผลแยกตาม *metric*
- ตาราง: ผลแยกตามชนิดข้อมูล
- ผลทดสอบ *H1 (*ไม่ได้รับการสนับสนุน) และ *H2 (*มี *2 paper)*
- ความยากกับการชนะ: *noise* สัมพันธ์ แต่ *IR* ไม่สัมพันธ์

- *SMOTE* แบบอื่นที่รายงานแยก และ *3 paper* ที่ตัดออกพร้อมเหตุผล
- ข้อแนะนำว่าควรอ่านผลชนะ *SMOTE* อย่างไร

7. Can the Reported Results Be Checked?

- ตาราง: ความละเอียดของการรายงานผล *6* ระดับ
- *14* จาก *57 paper* ไม่มีคู่ค่ารายชุด และ *H3: dataset 12.5%* ที่ลิสต์ไว้ไม่มีคู่ค่ากับ *SMOTE*
- การยกผล *baseline* ข้ามเปเปอร์ และ "พิสูจน์ผิดไม่ได้จากสิ่งที่ตีพิมพ์" หมายความว่าอะไร

8. Recommendations for Reporting Data

- *checklist 8* ข้อ แต่ละข้อชี้กลับไปที่หัวข้อของข้อค้นพบ

สคริปต์อธิบาย *Data section:* ข้อมูลในงานตระกูล *SMOTE*

Oct 29, 2026 · @toon

วิธีใช้สคริปต์นี้

สคริปต์นี้เล่า *Data section* ทั้งส่วนในราว *15* นาที สำหรับผู้ฟังที่รู้จัก *SMOTE* แต่ยังไม่เคยเห็นงานของเรา เช่น อาจารย์ ทีมใน *lab* หรือ *P*

- **ข้อความปกติ = สิ่งที่พูด**
- ***[*แสดง: ...] = สิ่งที่ควรขึ้นจอหรือชี้ในตอนนั้น (ตาราง รูป หรือแท็บใน *Atlas)***
- **ตัวเลขทุกตัวตรงกับ *manuscript* และ *CONCLUSIONS.md* ฉบับ *29* ต.ค. *2026***

ส่วน	เวลาโดยประมาณ
เปิดเรื่อง	*1.5* นาที
เก็บข้อมูลอย่างไร	*1* นาที
ภาพรวม *benchmark*	*2* นาที
การเลือกและดัดแปลงข้อมูล	*1.5* นาที
ชื่อเดียวกันไม่ใช่ข้อมูลเดียวกัน	*1* นาที
ข้อมูลยากแค่ไหน	*2* นาที
ผลชนะ *SMOTE* มาจากไหน	*3* นาที
ตรวจย้อนผลได้ไหม	*1* นาที
ข้อแนะนำ และปิดท้าย	*2* นาที

***1.* เปิดเรื่อง: ทำไมต้องดูที่ข้อมูล**

[แสดง: ชื่อ section "How the SMOTE Literature Uses Data"]

ตลอด *25* ปีที่ผ่านมา มีวิธีต่อยอดจาก *SMOTE* ออกมามาก แทบทุกเปเปอร์บอกเหมือนกันว่าวิธีของตัวเองชนะ *SMOTE* คำถามของเราไม่ใช่ว่าวิธีไหนดีที่สุด แต่คือ "ชนะบนอะไร" เพราะผลการทดลองทุกอันน่าเชื่อถือได้เท่ากับข้อมูลที่ใช้ทดสอบเท่านั้น

ลองนึกภาพนักวิจัยคนหนึ่งที่อยากเทียบวิธี *SMOTE* สองตัว หรืออยากเลือก *benchmark* ให้วิธีใหม่ เขาจะเจอคำถามห้าข้อที่เปเปอร์แทบไม่เคยตอบไว้ในที่เดียว

1. ชื่อ *dataset* เดียวกันในสองเปเปอร์ คือข้อมูลเดียวกันจริงไหม
2. หลักฐานของทั้งวงการกว้างแค่ไหน
3. ข้อมูลที่ใช้ยากแค่ไหน นอกจากค่า *imbalance ratio*
4. เวลาเปเปอร์บอกว่าชนะ *SMOTE* มันชนะบนข้อมูลแบบไหน
5. ผู้อ่านตรวจย้อนผลนั้นได้ไหม

survey ที่มีอยู่ยังไม่มีเล่มไหนวิเคราะห์ด้านข้อมูลอย่างเป็นระบบ *section* นี้ตอบคำถามทั้งห้าข้อ จากเปเปอร์จริง *76* เรื่อง

ข้อสรุปที่จะพาไปถึงตอนท้ายคือ ผลชนะที่รายงานไว้มีอยู่จริง แต่ข้อมูลที่อยู่เบื้องหลัง แคบกว่า บรรยายไว้น้อยกว่า และตรวจย้อนได้น้อยกว่าที่เห็น

2. เราเก็บข้อมูลอย่างไร

[แสดง: ตัวเลข 76 paper ⟶ 73 paper, 1,654 dataset, 2,497 ผลเทียบ]

เราอ่านเปเปอร์ *76* เรื่องทั้งฉบับ ใช้ *73* เรื่องที่มีการทดลองบนข้อมูล แล้วจด *dataset* ทุกชุดที่เปเปอร์ใช้ ได้ *1,654* รายการ แต่ละรายการจดชื่อตามที่พิมพ์ แหล่งที่มา ขนาด จำนวน *feature* จำนวนคลาส และ *IR* พร้อมเลขตารางและหน้าที่เอาค่ามา

ทุก *dataset* ติดป้ายว่ามาถึงการทดลองอย่างไร มีห้าแบบ

- *original:* ใช้ตามที่แหล่งแจกมา
- *repository-defined:* ไฟล์สองคลาสที่ *KEEL* แบ่งไว้ให้ เช่น *yeast4*
- *modified:* ผู้เขียนดัดแปลงเอง เช่น เลือกคลาส *minority* เอง หรือลดตัวอย่าง

- *synthetic:* ผู้เขียนสร้างขึ้นเอง
- บอกไม่ได้: เปเปอร์ไม่ให้ข้อมูลพอจะตัดสิน

ฝั่งผลลัพธ์ เราลอกค่าที่เปเปอร์พิมพ์ไว้ของวิธีที่เสนอกับของ *SMOTE* ทีละชุดข้อมูล ทุก *metric* ที่ตารางเดียวกันรายงาน ได้ *2,497* คู่จาก *44* เปเปอร์ เราไม่ได้รันการทดลองใหม่ เราอ่านสิ่งที่เขาตีพิมพ์

ทุกค่าตรวจกับ *PDF* อีกรอบ ค่าของ *metric* หลักลอกสองรอบแยกกันแล้วตรงกันทุกค่า *839* จาก *839* แถว และทุกตัวเลขย้อนกลับไปหาตารางและหน้าในเปเปอร์ได้

3. ภาพรวม *benchmark:* จำนวนชุดไม่เท่ากับจำนวนแหล่ง

*[*แสดง: *771* ชื่อ ⟶ *680 dataset* ⟶ *459 family]*

ดูเผินๆ วงการนี้ดูหลากหลายมาก มีชื่อ *dataset* ต่างกัน *771* ชื่อ แต่พอรวมชื่อที่สะกดต่างกันแค่เครื่องหมาย เหลือ *680 dataset* และพอรวม *split* ที่หั่นมาจากแหล่งเดียวกัน เช่น *yeast4* กับ *yeast5* เหลือแหล่งจริง *459* แหล่ง

และการใช้งานกระจุกมาก *463* จาก *680 dataset* ถูกใช้ในเปเปอร์เดียว ส่วนครึ่งหนึ่งของการใช้งานทั้งหมดตกอยู่ที่ *37* แหล่ง *ecoli* อยู่ใน *42* เปเปอร์ *yeast 39 glass 35* จาก *73* เกือบครึ่งวงการใช้สามแหล่งนี้ และ *benchmark* ที่นิยมเป็นข้อมูลเล็ก ครึ่งหนึ่งมีไม่เกิน *800 instance* และไม่เกิน *9 feature*

*[*แสดง: ตัวอย่าง *yeast 14 split]*

การหั่น *split* เปลี่ยน *task* จริง *yeast 14 split* มี *IR* ตั้งแต่ *2.5* ถึง *41.4* แต่ไม่เปลี่ยนแหล่ง ทุก *split* ใช้ *domain* และ *feature* ชุดเดิม บางคู่ใช้ *minority* ชุดเดียวกันด้วย เช่น *yeast4* กับ *yeast-0-5-6-7-9_vs_4* ใช้ *minority 51* ตัวเดียวกัน

ผลบน *split* ของแหล่งเดียวกันก็ไม่อิสระต่อกัน ใน *11* เปเปอร์ ขนาดของความได้เปรียบเหนือ *SMOTE* คล้ายกันมากกว่าเมื่ออยู่ในแหล่งเดียวกัน (*p = 0.005)*

ผู้อ่านได้อะไร: เปเปอร์ที่บอกว่าทดสอบ *40* ชุด อาจมาจากแหล่งจริงแค่ไม่กี่แหล่ง ต้องนับจำนวนแหล่งควบคู่ และอย่านับแต่ละ *split* เป็นหลักฐานอิสระเวลาทดสอบนัยสำคัญ

4. การเลือกและดัดแปลงข้อมูล

*[*แสดง: ตารางชนิดข้อมูล *534 / 470 / 331 / 120 / 199]*

ใน *1,654* รายการ มี *original 534 repository-defined 470* ผู้เขียนดัดแปลงเอง *331* สร้างเอง *120* และอีก *199* บอกไม่ได้เลยว่าได้มาอย่างไร เท่ากับว่าราวหนึ่งในสี่ของข้อมูลที่ใช้ทดสอบไม่ใช่ข้อมูลต้นฉบับที่คนอื่นหยิบมาใช้ได้ตรงๆ

การดัดแปลงไม่ได้มีแบบเดียว หลักๆ มีสองแบบ แบบแรกคือเปลี่ยนโครงสร้างคลาส *177* รายการ ส่วนใหญ่เอาคลาสเดียวมาสู้กับที่เหลือ แบบที่สองคือเพิ่ม *IR* โดยตั้งใจ *147* รายการ เกือบทั้งหมดใช้วิธีสุ่มลด *minority* ให้เหลือน้อยลง

ประเด็นที่อยากให้จำคือ การดัดแปลงไม่ใช่ความผิด ปัญหาคือการไม่ประกาศ เปเปอร์บอกเหตุผลของการดัดแปลงแค่ *15* จาก *39* เรื่อง และ *93* จาก *331* รายการทำซ้ำไม่ได้เพราะขาดข้อมูล เช่น ไม่พิมพ์ขนาดของชุดที่ได้ ไม่บอก *IR* เป้าหมาย ไม่บอกว่าคลาสไหนเป็น *minority*

ตัวอย่างที่เห็นภาพชัด: ชื่อไฟล์ *KEEL* อย่าง *yeast-0-5-6-7-9_vs_4* บอกอยู่แล้วว่าคลาสไหนสู้กับคลาสไหน แต่เปเปอร์ที่เลือก *minority* เองแล้วพิมพ์แค่คำว่า "*Yeast*" ไม่ได้บอกอะไรผู้อ่านเลย

ผู้อ่านได้อะไร: รู้ว่าต้องมองหาอะไรก่อนเชื่อผล คือเปเปอร์บอกไหมว่าดัดแปลงอะไร และพิมพ์ลักษณะของชุดที่ใช้จริงไหม

5. ชื่อเดียวกันไม่ใช่ข้อมูลเดียวกัน

*[*แสดง: ตัวอย่าง *thyroid, dermatology, ecoli, pima]*

คำถามง่ายๆ คือ ถ้าสองเปเปอร์รายงานผลบน "*ecoli*" เอาค่ามาเทียบกันได้ไหม คำตอบคือบ่อยครั้งไม่ได้ ใน *192 dataset* ที่ถูกพิมพ์ขนาดไว้ในอย่างน้อยสองเปเปอร์ มี *90 dataset* ที่ขนาดไม่ตรงกัน *thyroid* มีทั้ง *7,200* และ *720 ecoli* มี *336, 327, 310* และ *301 pima* มี *768, 769, 635* และ *590*

*[*แสดง: ตารางนิยาม *IR]*

IR ก็เช่นกัน เราเจอนิยามที่พิมพ์จริงอย่างน้อย *9* แบบ บางแบบแปลงหากันไม่ได้ *IR* เท่ากัน *10* ในสองเปเปอร์จึงอาจหมายถึงความไม่สมดุลคนละระดับ และค่าที่ผิดก็ถูกส่งต่อกันได้ *MC-CCR* และ *MC-RBO* พิมพ์ *IR* ของ *vehicle* เป็น *1.17* ซึ่งไม่มีสูตรไหนให้ค่านี้ได้

แม้แต่ในเปเปอร์เดียวก็สับสนได้ *MWMOTE* นับ *Satimage* กับ *Statlandsat* เป็นสองชุด ทั้งที่จริงคือข้อมูลชุดเดียวกัน แค่เป็นทั้งชุดกับไฟล์ *train*

ผู้อ่านได้อะไร: ก่อนเทียบตัวเลขข้ามเปเปอร์ ต้องเช็กก่อนว่าเป็นไฟล์เดียวกัน แบ่งคลาสแบบเดียวกัน และใช้สูตร *IR* เดียวกัน

6. ข้อมูลยากแค่ไหน

เปเปอร์แทบไม่บอกเลยว่าข้อมูลยากแค่ไหนนอกจาก *IR* มี *overlap* เป็นตัวเลขแค่ *36* รายการจากสองเปเปอร์ เราเลยวัดเอง เฉพาะชุดที่ตรวจตัวตนได้จริง คือชื่อและขนาดตรงกับไฟล์สาธารณะ ได้ *113 task* แบบสองคลาส ที่ *41* เปเปอร์ใช้

*[*แสดง: รูปจุด *safe / borderline / rare / outlier* จากแท็บ "ความยากที่วัดได้" ใน *Atlas]*

วิธีวัดเข้าใจง่าย เราดู *minority* ทีละตัว แล้วดูเพื่อนบ้านที่ใกล้ที่สุดห้าตัว ถ้ารอบตัวเป็นพวกเดียวกันเกือบหมด คือ *safe* ถ้าปนกันครึ่งๆ คือ *borderline* ถ้าเกาะกลุ่มเล็กๆ คือ *rare* ถ้าโดดเดี่ยวกลางฝูง *majority* คือ *outlier* สัดส่วนของ *borderline* กับ *outlier* รวมกันเรียกว่า *noise index* ทุกเกณฑ์ที่ใช้มีอ้างอิง ไม่ได้ตั้งเอง

ผลที่ได้มีสามเรื่อง

- ลักษณะเด่นคือตัวอย่างน้อย: *79* จาก *113 task (70%)* มี *minority* ไม่ถึง *10* ตัวต่อ *feature*
- *IR* ไม่บอกความยาก: *IR* กับ *noise* แทบไม่สัมพันธ์กัน (***ρ*** *= 0.15) haberman* มี *IR* ต่ำแต่ *noise* สูงถึง *0.84*
- ข้อมูลที่ตรวจได้เป็นตารางเล็กมิติต่ำ: *feature* มัธยฐาน *9* ส่วน *59* รายการที่เกิน *100 feature* ตรวจไม่ได้เลยสักชุด

*[*แสดง: ตารางชุด *dataset* อ้างอิง *27 task]*

จากที่วัดมา เราคัดชุด *dataset* อ้างอิง *27 task* ให้ผู้อ่านหยิบไปใช้ได้เลย ครอบทุกโปรไฟล์ความยากและทุกช่วง *IR* ในแต่ละกลุ่มเลือกชุดที่คนใช้บ่อยที่สุด เพื่อเทียบกับงานเก่าได้ บวกชุดที่ *noise* ต่ำสุดกับสูงสุด เพื่อให้ครอบช่วง

ผู้อ่านได้อะไร: รู้ว่าข้อสรุปจาก *benchmark* ยอดนิยมพูดแทนได้แค่ตารางเล็กมิติต่ำ รู้ว่า *IR* อย่างเดียวไม่พอ และได้ *benchmark* พร้อมใช้ที่รู้ลักษณะครบ

7. ผลชนะ *SMOTE* มาจากไหน

นี่คือหัวใจของ *section* นี้ แบ่งเป็นห้าจังหวะ

*[*แสดง: *29 paper, 1,511* คู่, ชนะ *79.5%]*

จังหวะที่หนึ่ ภาพรวม มี *29* เปเปอร์ที่พิมพ์ค่ารายชุดของทั้งวิธีที่เสนอและ *SMOTE* ไว้ในตารางเดียวกัน เทียบได้ *1,511* คู่ วิธีที่เสนอชนะ *1,107* เสมอ *102* แพ้ *286* คือชนะราว *4* ใน *5* ของคู่ที่ตัดสินได้ แต่ *23* จาก *29* เปเปอร์ก็มีอย่างน้อยหนึ่งชุดที่ *SMOTE* ชนะ

*[*แสดง: ตารางแยก *metric]*

จังหวะที่สอง ขึ้นกับ *metric* บน *AUC, G-mean, F-measure* และ *recall* ชนะ *76–83%* แต่บน *precision* ชนะแค่ *57%* และบน *specificity SMOTE* ชนะ *6* ใน *7* แปลว่าวิธีใหม่มักหา *minority* เจอมากขึ้น แลกกับการทายผิดฝั่ง *majority*

*[*แสดง: ตารางแยกชนิดข้อมูล]

จังหวะที่สาม *H1* สมมติฐานที่เราตั้งไว้คือ วิธีใหม่น่าจะชนะบ่อยกว่าบนข้อมูลที่ผู้เขียนดัดแปลงเอง ผลคือไม่ใช่ ข้อมูลดัดแปลงชนะ *75.7%* น้อยกว่า *original* ที่ *79.3%* ด้วยซ้ำ เราใช้โมเดลที่คุมความต่างระหว่างเปเปอร์ ทิศทางยังกลับด้าน แต่พอเปลี่ยนวิธีนับก็ไม่มีนัยสำคัญ สรุปได้แค่ว่าการดัดแปลงข้อมูลไม่ได้ทำให้ชนะง่ายขึ้น

คำถามที่ตามมาคือ เขาดัดแปลงข้อมูลเพราะอะไร มีแค่ *15* จาก *39* เปเปอร์ที่เขียนเหตุผลไว้ และมีสองเหตุผลหลัก อย่างแรกคือแปลงให้เป็นโจทย์สองคลาส *7* เปเปอร์ เพราะวิธีถูกออกแบบมาสำหรับ *binary* อย่างที่สองคือ เพิ่ม *imbalance* ให้สูงขึ้น *7* เปเปอร์ เพื่อสร้างสภาพที่วิธีอ้างว่าแก้ สรุปคือส่วนใหญ่ดัดแปลงให้ข้อมูลตรงกับโจทย์ ไม่มีเปเปอร์ไหนบอกว่าทำเพื่อความหลากหลายตรงๆ ส่วนอีก *24* เปเปอร์เราหาเหตุผลไม่เจอ

แล้วผลที่พอๆ กัน แปลว่าวิธีแก้ปัญหาได้สำเร็จไหม ยังสรุปแบบนั้นไม่ได้ ด้วยสามเหตุผล หนึ่ง เราเทียบกับ *SMOTE* อย่างเดียว ชนะ *SMOTE* ไม่ได้แปลว่าแก้ปัญหาได้ สอง ข้อมูลดัดแปลงที่อยู่ในการเปรียบเทียบส่วนใหญ่เป็นการเลือกคลาส (*110* จาก *143* แถวในชุดกติกา *A)* มีแค่ *29* แถวที่เพิ่ม *IR* เพราะเปเปอร์ที่เพิ่ม *IR* เยอะอย่าง *k-means SMOTE* กับ *G-SMOTE* ไม่ได้รายงานผลรายชุดเทียบ *SMOTE* เลย สาม *IR* ไม่สัมพันธ์กับการชนะ ถ้าวิธีแก้ปัญหา *imbalance* ได้จริง ควรเห็นว่ายิ่ง *IR* สูงยิ่งได้เปรียบ แต่ไม่เห็น

สิ่งที่พูดได้อย่างปลอดภัยคือ การดัดแปลงไม่ได้ทำให้ผลชนะ *SMOTE* สูงเกินจริง แต่หลักฐานที่ตีพิมพ์ยังไม่พอบอกว่าวิธีแก้ปัญหาที่ตั้งใจแก้ได้สำเร็จ

จังหวะที่สี่ *H2* เปเปอร์ที่ใส่ชุดมาตรฐานมาแค่ชุดเดียวเพื่อให้ดูน่าเชื่อถือ มีแค่สองเรื่อง คือ *MWMOTE* กับ *RUSBoost* และอัตราชนะบนข้อมูลอื่นก็เท่ากับเปเปอร์ทั่วไป (*80.0%* กับ *80.3%)* น้อยเกินจะทดสอบ และไม่เห็นรูปแบบที่ผิดปกติ

*[*แสดง: การ์ด *H1–H3* ในแท็บ "ชนะ *SMOTE*" ของ *Atlas]*

จังหวะที่ห้า สิ่งที่บอกได้จริงคือความยาก พอเอาผลชนะมาวางคู่กับความยากที่เราวัดเอง พบว่า *noise index* ยิ่งสูง วิธีใหม่ยิ่งชนะบ่อย เพิ่ม *0.1* แล้ว *odds* ชนะเพิ่มเป็น *1.15* เท่า (*p = 0.005)* ในขณะที่ *IR* ไม่สัมพันธ์เลย ตรงกับจุดอ่อนที่รู้กันของ *SMOTE* คือสร้างตัวอย่างในบริเวณที่ *minority* ปนกับ *majority* และนี่คือหลักฐานที่ใกล้กับคำว่า "วิธีแก้ปัญหาที่ตั้งใจแก้ได้" ที่สุด เพราะหลายวิธีอ้างว่าแก้ปัญหา *borderline* และ *noise* ผลนี้มาจาก *72* ไฟล์ใน *20* เปเปอร์ จึงเป็นการวิเคราะห์เชิงสำรวจ

ส่วนเปเปอร์ที่เทียบกับ *SMOTE* แบบอื่น เช่น *OVO-SMOTE* หรือ *SMOTE* ที่ห่อด้วย *ensemble* เรารายงานแยก *12* เปเปอร์ และตัดออก *3* เรื่องที่เทียบไม่ได้จริงพร้อมเหตุผล

ผู้อ่านได้อะไร: อ่านผลชนะ *SMOTE* คู่กับ *metric* เสมอ และคาดได้ว่าวิธีใหม่จะได้เปรียบชัดบนข้อมูลที่ *minority* อยู่ตรงขอบหรือโดดเดี่ยว ไม่ใช่บนข้อมูลที่ *IR* สูง

8. ผู้อ่านตรวจย้อนผลได้ไหม (*H3)*

*[*แสดง: ตาราง *granularity 47 / 8 / 5 / 5 / 3 / 5]*

คำถามสุดท้ายคือ ถ้าผู้อ่านอยากตรวจว่าเปเปอร์ชนะจริงไหม ทำได้ไหม จาก *73* เปเปอร์ มี *47* เรื่องที่ให้ผลรายชุดครบ ที่เหลือให้แค่บางส่วน กราฟ ค่าเฉลี่ย อันดับ หรือไม่เทียบเลย และใน *57* เปเปอร์ที่ใช้ *SMOTE* เป็น *baseline* มี *14* เรื่องที่ไม่มีคู่ค่ารายชุดกับ *SMOTE* เลย

แม้แต่เปเปอร์ที่มีตารางรายชุด ก็มี *dataset 12.5%* ที่ลิสต์ไว้ในตารางลักษณะข้อมูล แต่ไม่มีผลเทียบกับ *SMOTE (119* จาก *952* รายการ) ชุดที่หายมากที่สุดคือชุด *synthetic* และชุดที่บอกที่มาไม่ได้

เรายังเจอการยกผล *baseline* ข้ามเปเปอร์ เช่น *EMDO* ใช้ค่าเดียวกับ *AMDO* ทุกค่าโดยไม่ประกาศ ผู้อ่านจึงแยกไม่ได้ว่าเทียบในเงื่อนไขเดียวกันหรือไม่

ตรงนี้ต้องพูดให้ชัด: เราไม่ได้บอกว่าเปเปอร์เหล่านี้ผิด สิ่งที่บอกคือผลของเขาพิสูจน์ผิดไม่ได้จากสิ่งที่ตีพิมพ์ ผู้อ่านแยกไม่ได้ว่าค่าเฉลี่ยที่ดีขึ้น มาจากการชนะสม่ำเสมอ หรือชนะขาดแค่ไม่กี่ชุด

9. ข้อแนะนำ *8* ข้อ

*[*แสดง: *checklist 8* ข้อ]

จากทุกอย่างที่เล่ามา เราสรุปเป็น *checklist 8* ข้อสำหรับคนที่จะเขียนเปเปอร์เรื่องต่อไป ทุกข้อมาจากปัญหาที่เจอจริงในส่วนก่อนหน้า

1. บอกแหล่งและ *version* ของทุก *dataset* และใช้ทั้งชุดหรือแค่ไฟล์ *train (*มาจากส่วนที่ *5)*
2. บอกว่าคลาสไหนเป็น *minority* และเพราะอะไร ในเนื้อความ (ส่วนที่ *4)*

3. ประกาศการดัดแปลงทุกแบบ และพิมพ์ขนาดกับจำนวนคลาสของชุดที่ใช้จริง (ส่วนที่ *4)*
4. บอกสูตร *IR* ไม่ใช่แค่ค่า (ส่วนที่ *5)*
5. รายงานจำนวนแหล่งข้อมูลคู่กับจำนวน *dataset* และรวม *split* ของแหล่งเดียวกันเวลาทดสอบนัยสำคัญ (ส่วนที่ *3)*
6. รายงานผลรายชุดเทียบ *plain SMOTE* ทุก *metric* แยกชุดมาตรฐานกับชุดดัดแปลง (ส่วนที่ *7* และ *8)*
7. แยกชุดที่ใช้จูนออกจากชุดวัดผล และรัน *baseline* เองแทนการยกมา (ส่วนที่ *8)*
8. รายงานตัววัดว่า *minority* อยู่ตรงไหน เช่นสัดส่วน *safe, borderline, rare, outlier* คู่กับ *IR (*ส่วนที่ *6* และ *7)*

ข้อสังเกต: ทุกข้อเป็นการเพิ่มคำอธิบายไม่กี่บรรทัดในเปเปอร์ ไม่ต้องทดลองเพิ่ม ยกเว้นข้อ *8* ที่ต้องคำนวณเพิ่มเล็กน้อย

10. ปิดท้าย

*[*แสดง: ข้อสรุปประโยคเดียว]

ถ้าจะจำ *section* นี้ได้แค่ประโยคเดียว คือ ผลชนะที่รายงานไว้มีอยู่จริง แต่ข้อมูลเบื้องหลังแคบกว่า บรรยายไว้น้อยกว่า และตรวจย้อนได้น้อยกว่าที่เห็น

- แคบกว่า: หลายร้อยชื่อมาจากแหล่งยอดนิยมไม่กี่แหล่ง ส่วนใหญ่เป็นตารางเล็กมิติต่ำ
- บรรยายไว้น้อยกว่า: ชื่อเดียวกันมีหลายเวอร์ชัน *IR* มีหลายนิยาม และการดัดแปลงจำนวนมากทำซ้ำไม่ได้
- ตรวจย้อนได้น้อยกว่า: *14* จาก *57* เปเปอร์ไม่มีคู่ค่ารายชุด และแม้เปเปอร์ที่มีก็ไม่ครบทุกชุด

ในส่วนที่ตรวจได้ วิธีใหม่ชนะ *SMOTE* จริงราว *4* ใน *5* แต่ความได้เปรียบขึ้นกับ *metric* และไปอยู่บนข้อมูลที่ *minority* อยู่ตรงขอบ ไม่ได้มาจากการดัดแปลงข้อมูล สิ่งที่วงการต้องการจึงไม่ใช่ *benchmark* เพิ่ม แต่คือการบรรยายข้อมูลให้ระบุตัวได้ วัดความยากนอกจาก *IR* และรายงานผลรายชุดให้ครบ

ผู้อ่านส่วนนี้ได้อะไรกลับไป

- วิธีอ่านผล *SMOTE* ในเปเปอร์อย่างระมัดระวัง: ดู *metric* ดูจำนวนแหล่ง ดูว่าตรวจย้อนได้ไหม
- ความคาดหวังที่ตรงกับความจริง: วิธีใหม่ได้เปรียบบนข้อมูลที่ *noise* สูง แลกกับ *precision*
- ชุด *dataset* อ้างอิง *27 task* ที่รู้ลักษณะครบ ใช้เป็น *benchmark* ได้ทันที

- *checklist 8* ข้อสำหรับเขียนเปเปอร์เรื่องต่อไป

ขอบคุณครับ ยินดีรับคำถาม

คำถามที่อาจถูกถาม

คำถาม	คำตอบสั้น
ทำไมไม่รันการทดลองใหม่เอง	คำถามคือสิ่งที่ตีพิมพ์แล้วบอกอะไรผู้อ่าน การรันใหม่ตอบคำถามอีกแบบ และส่วนนั้นอยู่ใน *Section 7* ของ *P*
เทียบตัวเลขข้ามเปเปอร์ได้อย่างไร ในเมื่อสเกลต่างกัน	ไม่ได้เทียบค่า เทียบแค่ว่าใครสูงกว่าภายในตารางเดียวกัน และทุกโมเดลใช้เปเปอร์เป็น *cluster*
เปเปอร์ที่รายงานหลาย *metric* ไม่ได้น้ำหนักมากเกินหรือ	ได้ จึงรายงานแบบหนึ่งผลต่อ *dataset (*ชนะ *409* แพ้ *76)* และแบบ *metric* เดียว (ชนะ *402* แพ้ *80)* คู่กัน ภาพไม่เปลี่ยน
H1 กลับด้าน แปลว่าข้อมูลดัดแปลงทำให้ชนะยากขึ้นไหม	ยังบอกไม่ได้ ทิศทางกลับด้านแต่ไม่ทนเมื่อเปลี่ยนหน่วยการนับ สิ่งที่พูดได้คือไม่พบหลักฐานว่าทำให้ชนะง่ายขึ้น
เขาดัดแปลงข้อมูลเพื่ออะไร	*15* จาก *39* เปเปอร์ที่บอกเหตุผล: แปลงเป็นสองคลาสให้ตรงกับวิธี (*7)* และเพิ่ม *imbalance* เพื่อสร้างสภาพที่ยากขึ้น (*7)* ไม่มีเปเปอร์ไหนบอกว่าทำเพื่อความหลากหลายตรงๆ
ผลพอๆ กันบนข้อมูลดัดแปลง แปลว่าวิธีแก้ปัญหาได้สำเร็จไหม	ยังสรุปไม่ได้: เทียบกับ *SMOTE* อย่างเดียว, ข้อมูลที่เพิ่ม *IR* แทบไม่ถูกรายงานรายชุด (*29* จาก *143* แถว) และ *IR* ไม่สัมพันธ์กับการชนะ สัญญาณที่ใกล้ที่สุดคือวิธีใหม่ชนะบ่อยขึ้นบนข้อมูลที่ *noise* สูง
ผลเรื่อง *noise* เชื่อได้แค่ไหน	เป็นการวิเคราะห์เชิงสำรวจ *72* ไฟล์ *20* เปเปอร์ ทิศทางเดียวกันทุกแบบ แต่พอนับหนึ่งผลต่อไฟล์ *p* เหลือ *0.08* เป็นสัญญาณที่ควรตรวจต่อ
ทำไมตัด *KNNOR, RBBoost, MC-MBRC*	*KNNOR* มีแต่ค่าเฉลี่ย *RBBoost* เอาค่ามาจากคนละตารางที่ไม่เคยเทียบกัน *MC-MBRC* หัวคอลัมน์ไม่บอกว่าคือ *SMOTE* ข้อมูลยังเก็บไว้ครบ

ถ้าต้องการดูข้อมูลเต็ม เปิด *SMOTE25 Dataset Atlas* ทุก *dataset* ทุกผลเทียบดูและกรองได้